

G5中間報告書

YouTubeのエンゲージメント予測

● 概要

本研究では、YouTube動画のエンゲージメント予測を目的としてデータマイニングを行う。YouTubeは世界最大級の動画共有プラットフォームであり、多くの投稿者が日々動画を投稿している。しかし、投稿した動画が視聴者からどの程度の評価を受けるかを事前に予測することは容易ではない。

そこで本研究では、YouTube動画の各種特徴量から高評価数や低評価数を予測するモデルの構築を目指す。また、単なる予測に留まらず、どのような特徴がエンゲージメントに影響を与えるのかを分析し、高評価につながる要因を明らかにすることを目的とする。

この実験により、動画投稿者がコンテンツ改善や動画企画を行う際の参考となる知見を得ることができるようになる。

● データセット

本研究では、Kaggleで公開されている「Youtube Trending Dataset」を利用した。データセットには、YouTubeのトレンド動画に関する様々な情報が含まれており、再生回数、コメント数、高評価数、低評価数などのデータが収録されている。

データセットURL: <https://www.kaggle.com/datasets/pavandas/youtube>

目的変数として likes および dislikes を利用する予定であるが、現段階では likes の予測のみを行っている。

● 進行計画

1. 5-7週目(これまでにやったこと)

a. データ前処理


データセットから数値型の特徴量を抽出し、機械学習モデルで扱える形式へ整形した。また、一部の特徴量については加工方法の検討を行った。

b. 線形回帰モデルの構築

ベースラインモデルとして線形回帰を用い、likes の予測を行った。学習結果から各説明変数と likes の関係性を分析し、予測に有効な特徴量について考察した。

C. データ可視化

線形回帰モデルから得られた考察結果を検証するため、散布図や相関関係を示すグラフを作成した。可視化によって特徴量と likes の関係を確認し、考察を深めた。
一部比較に使用したプロットを添付する。



これはLikesとViews、Dislikes、Comment Countそれぞれとの関係を調べるために行ったものである。プロットよりDislike、Comment Countのプロットには複数の直線がみられた。これらの直線をクラスタリングできたら予測が容易になるのではないかといった考察ができた。


d. ランダムフォレストとモデル評価

予測性能の評価にはMAPE (Mean Absolute Percentage Error)を用いた。線形回帰モデルとランダムフォレスト回帰モデルを比較した結果、ランダムフォレスト回帰の方が大幅に小さいMAPEを示し、より高い予測性能を持つことが確認された。


決定係数は0.96、平均二乗誤差も求めたものの、データの特性上、レンジが極めて広いために巨大な数字になりやすく、信頼に欠けた。

e. 比較結果

以下は線形回帰モデルによる予測値と実際の値の比較をプロットしたものである。かなり荒い予測で、左右にばらけている事が分かる。



その後、より高い予測精度を得るためにランダムフォレスト回帰を行った。
以下にプロットを示す。先ほどの線形回帰モデルと比べて、よりまとまっていることがわかる。



また、実際にこれらのMAPEを比較してみると、線形回帰よりもランダムフォレスト回帰の方が大幅に良好な結果を示したため、今後はこちらを主なモデルとして実験を進める予定である。
その結果を以下に示す。

	線形回帰モデル	ランダムフォレスト
決定係数(R^2)	0.878723966686418	0.9599943128931042
平均二乗誤差(MSE)	5350577710.612664	1765011040.3794749
MAPE	1592.00%	60.39%

- 8週目
 - 散布図など各種プロットの作成
 - 考察結果の検証
 - 中間報告書の作成
- 9週目
 - ランダムフォレスト回帰モデルの詳細な評価
 - ハイパーパラメータ調整(ランダムフォレスト回帰そのものに対する知識レベルが低いため、優先順位は低い)

- 10週目
 - 特徴量重要度の分析
 - 重要特徴量の選定
 - テキスト特徴量の数値評価方法の検討
- 11～12週目
 - 特徴量エンジニアリング(テキスト特徴量の数値評価も兼ねている)
 - 前処理方法の改善
 - モデル性能の再評価
- 13週目
 - dislikes予測への拡張
 - ikes予測との比較分析
 - 最終実験
 - 結果整理および考察
- 第15週
 - 最終報告書作成
 - 発表資料作成