

YouTube トレンド動画 likes 予測

中間報告書 続編

ー リークの発見、段階分類への転換、チャンネル知名度の分析 ー

対象期間: 第10回～第12回 (2026年6月～7月)

データ: YouTube US トレンド動画 2017-2018 (ユニーク 5,817 件)

目次

0. 要旨

前回までの報告では、ジャンル分割と対数変換を施した Random Forest により likes 予測で $R^2=0.99$ という高い精度を報告していた。本続編では、この値が **3 段階のリークによる見かけ上の数字** であったことを突き止め、正しい評価設計のもとでの真の難易度を明らかにする。さらに、絶対数の回帰が困難であることを受けて問題設定を「段階分類」へと転換し、実用的な予測の形を整えた。最後に、チャンネルの知名度別に予測力を分析し、「**誰が投稿したか**」が予測を支配するという構造を定量的に示す。続く第 12 回では、段階分類の残る弱点であった likes のインフレ（分布シフト）を「時間相対比」ターゲットで補正し、未来情報を使わずに「低」段階の識別を回復させた（F1 0.13→0.40）。

結論として、投稿前情報だけによる likes 絶対数の予測は **真の $R^2 \approx 0.40$** にとどまり難しい。一方、likes を段階に分けて当てる分類なら **二値 AUC=0.86 / 4 段階 正解率 62% (± 1 段階 91%)** と実用域に達する。

1. 当初の高精度 ($R^2=0.99$) の正体

当初モデルの高い R^2 は、次の 3 つの問題が積み重なって生じた見かけ上の値だった。それぞれが独立に精度を底上げしており、すべてを取り除いて初めて真の予測力が見える。

#	リークの種類	内容
1	同時生起変数のリーク	views / dislikes / comment_count は likes と同時に決まる量。これらを特徴量に入れると「予測」ではなく「逆算」になる。特徴量重要度の約 99%を占有していた。
2	動画の重複	全 37,236 行のうちユニーク動画は 5,817 件のみ。同一動画が複数日トレンド入りして重複し、同じ動画が学習と test の両方に分散していた。
3	ランダム分割による未来情報の混入	時系列を無視したランダム分割では「未来の動画で学習し過去を予測する」向きが混ざり、実運用（投稿前予測）と乖離する。

これら3つをすべて排除し、投稿時点で確定する特徴量のみ・動画重複除去・

trending_date 順の時系列分割 で評価し直した結果が次節である。

2. 真の難易度：投稿前 likes 予測

リークを断った正しい評価では、likes 絶対数の予測は 真の $R^2 \approx 0.40$ (± 0.20)、対数スケールの R^2 はほぼ 0 にとどまった。これは失敗ではなく、評価設計の重要性を示す誠実な結果である。

評価方法	実スケール R^2	対数 R^2	MAE
時系列分割 (正式)	0.396	-0.007	25,095
ランダム K 分割 (参考)	0.362	0.171	24,193

表1. 投稿時点特徴量・動画重複除去後の likes 予測性能




図1. 時系列分割による実際値×予測値 (投稿前特徴量のみ)

2.1 特徴量の寄与と方向性の探索

投稿前情報の範囲で何が効くかを切り分けた。重要なのは、内容特徴（タイトル・タグ）だけではほとんど説明できず、チャンネルの過去実績が支配的だという点である。

設定	実 R^2	対数 R^2	補足
数値特徴（チャンネル込み）	0.409	0.093	基準
+ タイトル/タグ TF-IDF(300 語)	0.448	0.107	テキストは効く
内容特徴のみ（チャンネル除外）	-0.073	-0.946	説明不能
エンゲージ率 likes/views 予測	0.426	—	比なら少しマシ
高 likes 二値分類 (>中央値)	—	—	AUC=0.82

表2.3 方向の探索（精度向上・分析・問題設定変更）

チャンネル実績を除くと R^2 がマイナスに転落することから、「**内容より発信者**」が決定的だと分かる。一方、二値分類に問題を変えると AUC=0.82 と実用的になり、これが次章の方向転換につながった。

3. 方向転換：絶対数の回帰から段階分類へ

絶対数を当てるのが難しいため、likes を段階に分け「どの段階か」を当てる分類に問題を設定し直した。どこまで細かく刻めるかを診断したのが表 3 である。

設定	正解率/指標	ランダム	±1 段階許容
二値分類（中央値超え）	AUC 0.860	0.500	—
3 段階分類	0.694	0.333	0.971
4 段階分類	0.618	0.250	0.910
5 段階分類	0.517	0.200	0.882
10 段階分類	0.316	0.100	0.666
順位予測（Spearman ρ ）	0.620	—	—

表3. 刻む粒度と精度（投稿時点情報のみ・時系列評価）

4～5 段階が刻みと精度のバランス点であり、**4 段階分類（正解率 62%・±1 段階 91%）** を正式モデルとして採用した。

3.1 カテゴリによる予測しやすさの違い

予測のしやすさはカテゴリで大きく異なる。スポーツや教育は当てやすく、エンタメやゲームはほぼ予測不能だった。

カテゴリ	test 件数	R ²
Sports (17)	90	0.868
Education (27)	44	0.789
News & Politics (25)	53	0.583
Music (10)	135	0.408
Entertainment (24)	359	−0.106
Gaming (20)	34	−0.475

表4. カテゴリ別の likes 予測 R²（抜粋）

4. 第 11 回の改善

4.1 4 段階分類「低」段階の崩れと改善

4 段階分類は「低」段階が test で support=15・F1=0.125 と崩壊していた。原因は **分布シフト** である。test 期間の likes 中央値 (20,562) は学習期間 (5,642) の約 3.6 倍に上昇しており、likes 絶対値で境界を引くと未来データの大半が上位ビンに寄り「低」が痩せる。ビンの引き直し 4 方式を比較した。

ビン定義	正解率	±1 段階	低 support	低 F1	備考
v1 学習分位点 (現状)	0.616	0.911	15	0.125	崩壊
A 全データ分位点	0.567	0.911	37	0.282	妥協点
B 対数等幅	0.767	0.997	1	0.000	低が消滅
C チャンネル相対比	0.344	0.611	227	0.320	低が復活

表5. ビン境界4 方式の比較 (黄= 低段階が最も改善)




図2. v1 (学習分位点) と C (チャンネル相対比) の混同行列

「低」段階を救うには、ターゲットを **チャンネル相対比 (likes ÷ チャンネル学習期間平均)** に定義し直すのが最有効だが、問題が「実力比でどれだけ伸びたか」に変わるため全体正解率は低下する。絶対数を保つなら A (全データ分位点) が無難な妥協点である。

4.2 最低保証モデルの実用化

予測段階を「最低でもこの段階は伸びる」という下限とみなす使い方を、実用関数 **predict_floor()** に仕上げた。新規動画を入れると（下限段階・likes 下限値・保証成立率）を返す。安全率 **conf** を上げるほど控えめになり保証成立率が上がる。

conf (安全率)	最低保証成立率	平均下限段階	下振れ平均段数
argmax (通常)	0.851	2.26	1.27
0.5	0.881	2.17	1.17
0.7 (推奨)	0.950	1.78	1.14
0.9	0.994	0.99	1.00

表6. conf による保証の堅さと情報量のトレードオフ (緑=推奨設定)




図3. 最低保証成立率と平均下限段階のトレードオフ

推奨設定 **conf=0.7** では **最低保証 95%** を達成しつつ段階の情報量を保つ。段階別の保証成立率は 低=1.00 / 中低=0.98 / 中高=0.94 / 高=0.91 であった。

4.3 チャンネル知名度による予測力の違い

チャンネルを「学習期間内のトレンド入り本数」で層別し、予測しやすさを比較した（知名度の定義に未来情報を使わないよう学習期間のみで集計）。

群（学習期間トレンド入り）	test 件数	Spearman ρ	二値 AUC	対数 R^2
有名（6 本以上）	530	0.690	0.883	0.041
中堅（2～5 本）	315	0.751	0.947	0.459
無名（1 本のみ）	99	0.588	0.790	-0.770
新規（学習期間に未出現）	220	0.125	0.602	0.045

表7. チャンネル知名度別の予測力（緑=最良の中堅群、赤=予測不能の新規群）




図4. 知名度別の Spearman 順位相関と二値AUC (full=実績+内容/ content=内容のみ)

意外にも最も予測しやすいのは有名群ではなく **中堅群（AUC=0.947）** だった。有名チャンネルは話題性で上下に大きくブレるため過去平均だけでは当てきれない。そして **完全新規チャンネルはほぼ予測不能（AUC=0.602 ≒ コイン投げ）** であり、チャンネル実績が使えない瞬間に投稿前予測が崩壊することを示している。これは「誰が投稿したか」が支配的という第2章の知見を、チャンネル軸で裏付ける結果である。

5. 第12回の改善：時間相対比による分布シフトの補正

4.1 節の結論は「絶対値ビンは分布シフトで壊れ、チャンネル相対比（C）は問題そのものが難化する」だった。第12回では第三の道として **時間相対比**を検証した。likes を「その時期のトレンド動画の標準的な水準」で割った比でビンを切る。C が「発信者に対する相対」であるのに対し D は「時代に対する相対」であり、「どの動画が伸びるか」という問題の中身を保持したまま、スケールのインフレだけを取り除くことを狙う。




図5. トレンド動画likes の週次中央値インフレと分母の外挿3 方式

図5 が分布シフトの正体である。週次中央値は約7ヶ月で3.6倍になるが、その上がり方は緩やかなlog線形ではなく、**2018年3月頃に水準が一段跳ね上がる構造的なレジーム転換**を含む。したがって「分母（その時代の水準）」の作り方が結果を大きく左右する。分母は4方式を比較した：D1=その週の実中央値（オラクル、週が終わるまで確定しないため投稿前運用は不可）／D2=学習全期間のlog線形トレンドを外挿／D3=学習の直近8週のみで外挿／D4=学習最終水準をそのまま持ち越し（ランダムウォーク予測）。D2～D4は学習期間の情報しか使わない完全リークフリーである。

ターゲット定義	正解率	±1 段階	マクロ F1	低 support	低 F1	投稿前運用
v1 学習分位点（絶対	0.616	0.911	0.455	15	0.125	可

ターゲット定義	正解率	±1 段階	マクロ F1	低 support	低 F1	投稿前運用
値)						
A 全データ分位点 (絶対値)	0.567	0.911	0.489	37	0.282	可 (境界固定)
C チャンネル相対比	0.344	0.611	0.294	227	0.320	可
D1 週中央値 (実測)	0.355	0.847	0.357	165	0.432	不可 (分母未確定)
D2 全期間トレンド外挿	0.489	0.905	0.456	84	0.400	可
D3 直近 8 週外挿	0.204	0.553	0.182	621	0.346	可
D4 最終水準持ち越し	0.467	0.903	0.435	97	0.390	可

表8. ターゲット定義7 方式の比較 (黄= リークフリーで推奨のD2/D4)

結果は狙い通りとなった。リークフリーの **D2/D4** は「低」F1 が **0.39~0.40** と **v1** の **3 倍超に回復**し、±1 段階許容 0.90 とマクロ F1 は v1 と同水準を保った。代償はピタリ正解率の低下 (0.62→0.47~0.49) である。C (正解率 0.344・±1 段階 0.611) とは全指標で優位であり、「低を救いつつ問題を難化させない」という D の狙いは概ね成立した。




図6. 混同行列の比較: v1 (学習分位点) / C (チャンネル相対比) / D4 (時間相対比)

5.1 分母の設計から得られた 2 つの発見

第一に、**分母が最も正確な D1（実測週中央値）が最良ではない**。その週の実中央値で割ると「同時期にどんな動画と競合したか」というノイズが目的変数に混入し、投稿時点の特徴量からの学習可能性はむしろ下がる（正解率 0.355）。分母に求められるのは正確さより滑らかさである。

第二に、**急勾配の外挿は危険**である。レジーム転換後の急勾配だけで外挿した D3 は test 週の水準を中央値 2.55 倍に過大評価し、正解率 0.204 と崩壊した。転換後に水準が横ばいになる本データでは、最終水準の持ち越し（D4）が堅実で、実際 D2 とほぼ同等の成績を収めた。用途としては、「低」段階を含む安定した 4 段階が必要なら D2/D4 を、ピタリ正解率を最重視するなら従来の v1 を選ぶ、という使い分けを推奨する。

6. 結論と今後

本続編で得られた主要な知見は次の通り。

- **$R^2=0.99$ は 3 段階のリークの産物だった。** 同時生起変数・動画重複・ランダム分割を排すと真の R^2 は約 0.40 に下がる。
- **投稿前の likes 絶対数予測は本質的に難しい。** ただし段階分類（二値 AUC=0.86、4 段階 ± 1 段階 91%）なら実用的に予測できる。
- **予測を支配するのは発信者（チャンネル実績）。** 内容特徴のみでは説明不能で、新規チャンネルは予測不能になる。
- **最低保証という使い方が有効。** $\text{conf}=0.7$ で 95% の下限保証を提供できる。
- **分布シフトは時間相対比ターゲットで補正できる。** リークフリーの D2/D4 で「低」F1 が 0.13 $\rightarrow$ 0.40 に回復し、 ± 1 段階 0.90 を保った。分母は正確さより滑らかさが重要。

今後の方向性として、(1) チャンネル特徴を「投稿時点より前の実績のみ」で厳密集計する版の検証、(2) 未活用の投稿前特徴（概要欄・サムネイル画像）の追加、(3) 時間相対比（D2/D4）ターゲットの正式モデル化と最低保証モデルへの接続、を計画している。